

MAPAS AUTO-ORGANIZÁVEIS: Compactação de Imagem

Autores: Milene Karine GUBETTI e Éder Augusto PENHARBEL.

Identificação dos autores: Estudante do Curso Técnico em Informática Integrado ao Ensino Médio; Orientador IFC - campus Blumenau.

RESUMO

O objetivo do trabalho é estudar o potencial da aplicação de Mapas Auto-Organizáveis para compactação de imagens. Foram utilizadas algumas configurações para o mapa e foi escolhida uma delas para avaliar o desempenho da compactação com diversas imagens. Comparou-se os tamanhos de arquivos utilizando formatos de imagem TIFF (sem compactação), JPEG, PNG e o formato desenvolvido neste trabalho (SOM). Conclui-se que a técnica empregada obtém um resultado mais próximo do formato JPEG, superando o formato PNG.

INTRODUÇÃO E JUSTIFICATIVA

Uma imagem é composta por um conjunto de pixels, e pode ser representada por uma matriz, que armazena o RGB de cada pixel (GONZALES, 2002). Dentre os fatores que determinam o tamanho de uma imagem, em bytes, estão: a resolução e a qualidade, que depende do formato do arquivo.

O objetivo do presente trabalho é aplicar o modelo de redes neurais conhecido como Mapa Auto-Organizável proposto por Kohonen (2001). Busca-se a redução da variedade de valores de pixels da imagem para representar a imagem utilizando uma quantidade menor de bits, diminuindo o tamanho do arquivo que armazena a imagem. Um efeito colateral da redução da variedade de pixels é a diminuição da qualidade da imagem.

Mapa Auto-Organizável é um modelo computacional inspirado na biologia, que utiliza o modelo de treino não supervisionado. Ele é capaz de adaptar-se ou “aprender” a partir de dados chamados conjunto de treinamento, que é formado por padrões extraídos do problema em questão.

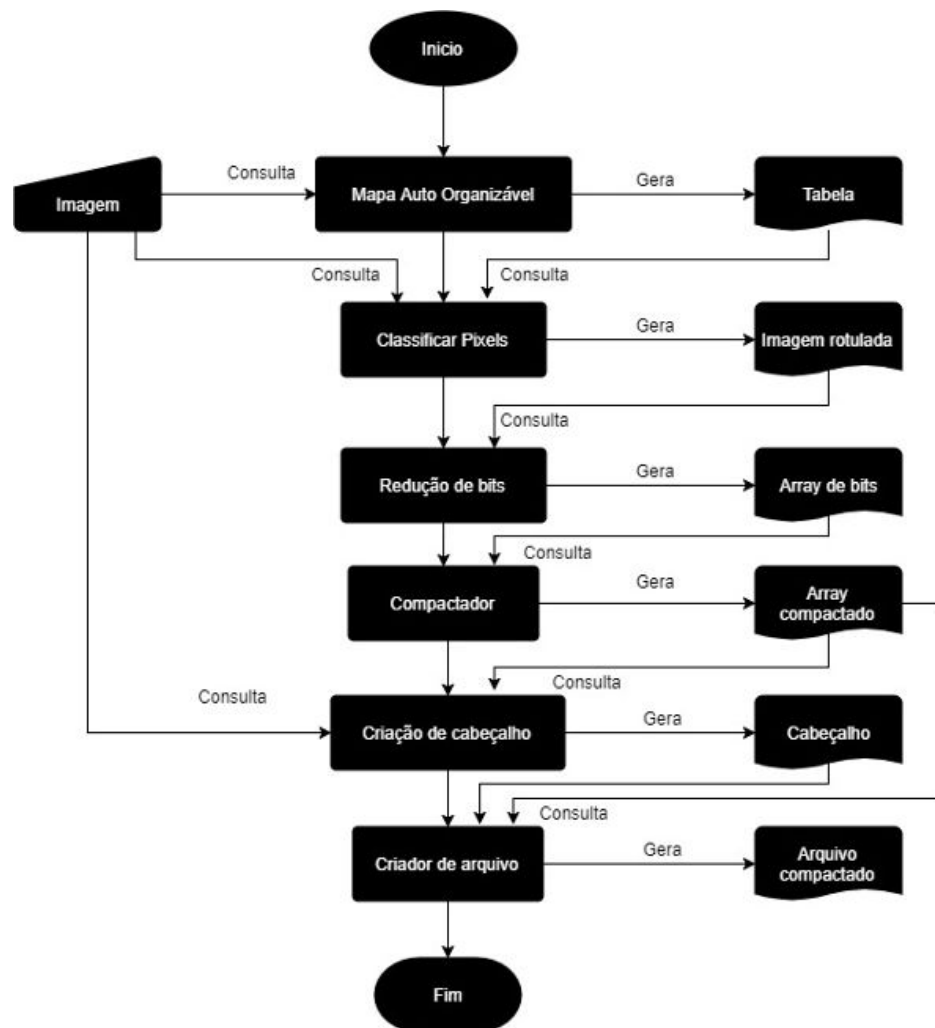
METODOLOGIA

A implementação, desenvolvida em Python, é capaz de ler uma imagem digital, amostrar os valores RGB dos pixels, eliminar a repetição desses valores, contando somente uma ocorrência de um determinado valor, aplicar o mapa auto-organizável e, por fim, criar uma tabela com os pixels mais significativos da imagem. O termo “significativos” pode ser interpretado como os neurônios presentes no mapa após o treinamento. Com a tabela

construída, é possível classificar cada pixel da imagem original, reduzindo a quantidade de bits necessários para armazenar a imagem.

Após esse processo é possível aplicar outros modelos de compactação à imagem compactada, como por exemplo, códigos de Huffman, obtendo imagens ainda mais compactadas. Por fim, a resolução da imagem, a quantidade de cores (dimensão do mapa), a tabela, e a imagem rotulada são salvos em um arquivo com formato .SOM. [Figura I]

Figura I - Fluxograma que descreve o funcionamento do algoritmo.



Fonte: autoria própria

RESULTADOS E DISCUSSÕES

O modelo de compactação utilizado é conhecido como compressão destrutiva, no qual não é possível reconstruir a imagem compactada exatamente igual a original. É possível

constatar isso utilizando o Erro Absoluto Médio (EAM) para estimar a qualidade da imagem compactada. A equação abaixo descreve como calcular o EAM.

$$EAM = \frac{\sum_{i=1}^n |y_i - x_i|}{n}, \text{ onde:}$$

n : resolução da imagem, y_i : pixels da imagem original e x_i : pixels da imagem compactada.

Nos exemplos a seguir, as Tabelas I e II mostram o valor do EAM para cada formato e o resultado visual pode ser observado nas Figuras II, III, IV e V.

Tabela I - Teste 1: comparação com uma imagem de 512x512.

Formato	Tamanho	EAM		
		R	G	B
tiff	768 KB	-	-	-
jpeg	36,9 KB	3,688976287841797	3,3127899169921875	5,202335357666016
png	468 KB	0	0	0
som	118 KB	4,765724182128906	4,362388610839844	4,594524383544922



Figura II - A imagem do teste 1 no formato TIFF.
Fonte: <https://goo.gl/VzzyFq>



Figura III - A imagem do teste 1 formato SOM.

Tabela II - Teste 2: comparação com uma imagem de 4334x2884.

Formato	Tamanho	EAM		
		R	G	B
tiff	35,7 MB	-	-	-
jpeg	1,16 MB	2,391125439786176	1,6803660153852358	2,4737765991831835
png	14,4 MB	0	0	0
som	2,49 MB	6,355918464266993	6,233098594028316	6,408463831767267



Figura IV - A imagem do teste 2 no formato TIFF.

Fonte: <https://goo.gl/h9di8d>



Figura V - A imagem do teste 2 no formato SOM.

CONSIDERAÇÕES FINAIS

Com os resultados obtidos, constata-se que o formato JPEG é mais eficiente, pois nos testes apresentou o menor tamanho, em bytes. Como no cálculo do EAM o PNG obteve 0 (zero) como resultado, isso significa que esse formato não perde informação e se mantém fiel à imagem original.

O formato SOM desenvolvido no trabalho, não superou o formato JPEG, mas mostrou ser mais eficaz que o PNG, e infelizmente perdeu nos testes do EAM. De modo geral, os resultados superaram as expectativas.

Python é uma linguagem de alto nível, dinamicamente tipificada, e é interpretada, por isso, consome mais processamento e torna a implementação lenta. Uma das soluções seria desenvolver o programa em uma linguagem de mais baixo nível que seja compilada, como por exemplo, C.

REFERÊNCIAS

CASTLEMAN, Kenneth R. **Digital Image Processing**. 2. ed. Prentice Hall, 1995.

GONZALEZ, Rafael C.; WOODS, Richard E.. **Digital Image Processing**. 2. ed. New Jersey: Prentice Hall, 2002.

HAYKIN, Simon. **Redes Neurais**: Princípios e prática. 2. ed. Porto Alegre: Bookman, 2001.
Tradução de: Paulo Martins Engel.

KOHONEN, Teuvo. **Self-Organizing Maps**. 3. ed. Berlin: Springer, 2001.